

COMPILADORES
TRABALHO SOBRE ANÁLISE LÉXICA
Reconhecimento de URLs (Uniform Resource Locators)

Em um compilador, o analisador léxico funciona em conjunto com o analisador sintático. Neste trabalho vamos desenvolver somente um **analisador léxico** para identificar URLs, incluindo: protocolo (opcional), domínio, porta (opcional), caminho (opcional), parâmetros de consulta (opcional) e fragmentos (opcional).

As URLs servem para identificar recursos na Internet e são compostas por várias partes distintas, cada uma com sua funcionalidade e sintaxe específica.

- **Protocolo:** indicam o método ou o tipo de serviço utilizado para acessar o recurso na web. Vamos considerar somente os protocolos http, https e ftp.
- **Domínio:** Nome do host ou IP que indica o servidor onde o recurso está localizado.
- **Porta (opcional):** Número da porta no servidor para conexão, padrão é 80 para HTTP e 443 para HTTPS.
- **Caminho:** Caminho no servidor onde o recurso específico está localizado.
- **Query (opcional):** Uma string de consulta que contém parâmetros adicionais para o servidor. Geralmente é formatada como chave=valor e separada por &. Eles são importantes em muitas aplicações web para filtrar conteúdo, identificar sessões, passar configurações, entre outros. Alguns exemplos comuns incluem:
 - ?user_id=123: Identifica um usuário específico.
 - ?page=4: Indica uma página específica nos resultados.
 - ?search=keyword: Passa uma palavra-chave de busca.
 - ?sort=asc&field=price: Instruções para ordenação de conteúdo.
- **Fragmento (opcional):** Uma âncora para ir a uma seção específica dentro do recurso.

Exemplos de URLs válidas

Exemplo 1: URL com HTTP

http://www.example.com:80/path/to/file?search=query&sort=ascending#section2

Nesta URL:

- o protocolo é http;
- domínio é www.example.com;
- porta é 80;
- caminho é /path/to/file;
- query é search=query&sort=ascending;
- o fragmento é section2.

Exemplo 2: URL com HTTPS

https://secure.example.com/register?user=abc&token=123#signup.

Nesta URL:

- o protocolo é https;
- domínio é secure.example.com;

caminho é /register;
Query é user=abc&token=123;
e fragmento é signup.

Exemplo 3: URL com FTP

ftp://example.com/downloads/file.zip

Nesta URL:

o protocolo é ftp;
domínio é example.com;
e caminho é /downloads/file.zip.

Gere uma gramática para este analisador léxico que contenha um token principal, que obviamente deve ser composto de outros tokens secundários. Use **expressões regulares** para identificar cada item das URLs.

Gere um programa Python que instancie a(s) classe(s) do analisador léxico (gerado(s) pelo ANTLR), receba o texto da URL a ser testada como parâmetro do programa (**o primeiro parâmetro de linha de comando deve ser a URL a ser testada**) e verifique se a entrada corresponde a uma URL válida.

Se sim, deve ser impresso o TOKEN (possivelmente URL) e o VALOR (que deve ser a URL de entrada), caso o token URL seja reconhecido.

Caso o token principal não tenha sido reconhecido, imprimir cada sub-token reconhecido.

Observações:

- 1) As saídas devem ser impressas no terminal, ou seja, não devem ser gerados arquivos de saída;
- 2) Lembre que **não é objetivo** verificar se a URL está sintaticamente correta. Por exemplo, query e fragmento não são comuns em URLs FTP, mas você aceitará, caso seja fornecido. Não esqueça que a análise **efetiva** será feita somente nas análises sintática e semântica;
- 3) Use "lexer grammar <NOME-DA-SUA-GRAMÁTICA>" no início da gramática;
- 4) **Não vale ponto**, mas investigue como gerar uma mensagem de **erro** (ou **aviso**) caso o token principal não seja reconhecido;
- 5) Entregue somente **dois arquivos**: a gramática e o programa em Python. Comprima os dois arquivos utilizando o compactador ZIP e coloque seu nome como nome do arquivo **zipado**;
- 6) Caso você não siga as recomendações acima, já perderá 2.0 pontos;
- 7) Consulte a monitora Jéssica Colares, no caso de dúvidas.